

Calibración de modelos de movilidad urbana basados en agentes mediante inferencias de máxima verosimilitud a partir de datos GPS de usuarios

Waldir Velásquez Quispe
Curso: Estadística Computacional

Resumen

Esta investigación presenta un enfoque metodológico para la calibración de modelos de movilidad urbana basados en agentes (ABM) utilizando inferencias de máxima verosimilitud aplicadas a trayectorias GPS de usuarios. Se discuten los fundamentos teóricos, el diseño del modelo, la construcción de la función de verosimilitud, la metodología de optimización y la validación con datos empíricos. Finalmente, se exponen conclusiones y recomendaciones para investigaciones futuras.

1. Introducción

Los modelos basados en agentes (ABM) han emergido como una herramienta poderosa para simular sistemas de transporte urbano complejos, permitiendo representar el comportamiento heterogéneo de viajeros individuales y sus interacciones con el entorno dinámico del transporte (Bastarion et al., 2023). La calibración de estos modelos mediante inferencias de máxima verosimilitud utilizando datos GPS representa un avance significativo en la precisión y validez de las simulaciones de movilidad urbana (Choi et al., 2025).

Siendo el modelo ABTS un ejemplo destacado que predice itinerarios de viaje individuales a partir de datos GPS y demográficos, logrando 83 % de precisión en Milwaukee y ofreciendo eficiencia y flexibilidad para la planificación urbana, aunque reduce su desempeño en zonas céntricas y eventos masivos (Choi et al., 2025).

2. Metodología

Modelos Basados en Agentes en Transporte Urbano

Los modelos basados en agentes representan a individuos como agentes autónomos con características independientes y reglas de comportamiento que guían sus decisiones y acciones (Bonabeau, 2002). La flexibilidad del marco ABM significa que las aplicaciones son amplias, ya que los agentes pueden representar cualquier tipo de entidad como personas, automóviles, carreteras o ciudades (Bastarionto et al., 2023).

Datos GPS en Análisis de Movilidad

Estos datos proporcionan información detallada sobre patrones de movimiento humano, incluyendo rutas, velocidades, y comportamiento temporal de los viajeros. La precisión espaciotemporal de los datos GPS permite analizar trayectorias individuales con un nivel de granularidad sin precedentes, facilitando la comprensión de la dinámica de la movilidad urbana (Wu et al., 2019).

Variable	Tipo Estadístico	Escala	Tendencia Central	Dispersión
Posición (Lat/Lon)	Continua Multivariante	Razón	Centroide trayectorias	Matriz covarianza
Timestamp	Serie Temporal	Intervalo	Moda horaria	Desv. estándar temporal
Velocidad	Continua	Razón	Media 25-50 km/h	DE 15-30 km/h
Aceleración	Continua	Razón	Media 0 m/s ²	DE 0.5-2 m/s ²
Tiempo de viaje	Continua	Razón	Mediana 20-45 min	DE 10-25 min
Frecuencia viajes	Conteo	Razón	Media 2.5-4.5	Varianza
Modos transporte	Categoría	Nominal	Proporciones	Entropía

Inferencia de Máxima Verosimilitud

La inferencia de máxima verosimilitud (MLE, por sus siglas en inglés) es un método estadístico fundamental para estimar parámetros de modelos probabilísticos que mejor explican los datos observados (Moradi et al., 2025).

$$\log L(\theta) = -\frac{1}{2} \sum_{i=1}^N ((D_i - S_i(\theta))^T \Sigma^{-1} (D_i - S_i(\theta)) + \log |\Sigma|)$$

$$L(\theta) = \prod_{i=1}^N P(D_i|\theta)$$

Preparación de Datos GPS

El proceso inicia con la limpieza y preprocesamiento de datos GPS brutos. Esto incluye la corrección de errores de medición, el filtrado de puntos anómalos, y el ajuste de trayectorias a la red de transporte mediante algoritmos de *map-matching* (Ilahi et al., 2019).

Construcción del Modelo Basado en Agentes

El modelo ABM debe incorporar múltiples componentes: generación de demanda de viajes, elección de modo, elección de ruta, y asignación de tráfico (Hörl & Balac, 2021).

Aplicación de Máxima Verosimilitud

La estimación por máxima verosimilitud se realiza maximizando $\log L(\theta)$ mediante métodos numéricos. Para reducir costo computacional, se recomienda el uso de modelos surrogados, muestreo inteligente y técnicas de reducción de dimensionalidad (McCulloch et al., 2022).

Heterogeneidad del Comportamiento

Los viajeros exhiben comportamientos heterogéneos influenciados por características sociodemográficas, espaciales y económicas (Hörl et al., 2018).

Modelado de Modos Emergentes

Los ABM calibrados con datos GPS se han utilizado para evaluar el impacto de vehículos autónomos (Fagnant & Kockelman, 2014), transporte bajo demanda (Inturri et al., 2021) y vehículos eléctricos (Ewert et al., 2021).

Decisión

Se adopta la metodología de calibración mediante inferencia de máxima verosimilitud (MLE) utilizando datos GPS de alta resolución como la opción más robusta para el modelo ABM.

Conclusiones

La investigación valida que la calibración de ABM con MLE y datos GPS es un marco eficaz para simular la movilidad urbana con alta precisión (hasta un 83 %). Como

trabajo futuro se recomienda explorar técnicas de inferencia aproximada, incorporar datos multimodales y desarrollar protocolos estandarizados de validación.

Referencias Bibliográficas

- Bastarianto, F.F., et al. (2023). *Agent-based models in urban transportation...* DOI: 10.1186/s12544-023-00590-5
- Bonabeau, E. (2002). *Agent-based modeling...* DOI: 10.1073/pnas.082080899
- Choi, M., Seo, J., & Hohl, A. (2025). *Programador de viajes basado en agentes...* DOI: 10.1007/s10109-025-00458-3
- Ewert, R., et al. (2021). *Improving vehicle routing...* DOI: 10.1016/j.trpro.2021.01.061
- Fagnant, D.J., & Kockelman, K.M. (2014). *Shared autonomous vehicles...* DOI: 10.1016/j.trc.2013.12.001
- Gómez, J.A., et al. (2021). *Bayesian inference methods...* DOI: 10.1016/j.ssci.2021.105522
- Hörl, S., & Balac, M. (2021). *Introducing the eqasim pipeline...* DOI: 10.1016/j.procs.2021.03.089
- Hörl, S., Balac, M., & Axhausen, K.W. (2018). *Discrete choice modeling and ABM...* DOI: 10.1016/j.procs.2018.04.087
- Ilahi, A., et al. (2019). *Agent-based model of Jakarta...* DOI: 10.1016/j.procs.2019.04.039
- Inturri, G., et al. (2021). *Shared transport systems...* DOI: 10.1016/j.tranpol.2021.01.002
- Kang, D., et al. (2018). *MLE in rail transit...* DOI: 10.3390/su10061752
- Kii, M., et al. (2021). *Decentralization and rail network...* DOI: 10.3390/su132313196
- Manley, E., et al. (2014). *Hybrid ABM traffic dynamics...* DOI: 10.1016/j.compenvurbsys.2013.11.002
- McCulloch, J., et al. (2022). *Calibrating ABM...* DOI: 10.18564/jasss.4791
- Moradi, S., et al. (2025). *ABM for crime prediction...* DOI: 10.1016/j.eswa.2025.129181
- Nussbaumer, R., & Kirao, L. (2022). *Geolocalizadores Cossypha natalensis...* DOI: 10.5751/JFO-00113-930208
- Saprykin, A., et al. (2019). *GEMSim GPU mobility simulator...* DOI: 10.1016/j.simpat.2019.03.002
- Wu, H., et al. (2019). *ABM of mobility based on phone data...* DOI: 10.3390/ij-gi8070313
- Zheng, N., et al. (2012). *Dynamic cordon pricing...* DOI: 10.1016/j.tra.2012.05.006