

Calibración de Modelos de Movilidad Urbana Basados en Agentes mediante Inferencias de Máxima Verosimilitud a partir de Datos GPS de Usuarios

1. Introducción

La planificación de la movilidad urbana requiere modelos predictivos precisos. Esta revisión sistemática examina la intersección crítica entre los Modelos de Movilidad Urbana Basados en Agentes (ABM) y la Estimación de Máxima Verosimilitud (MLE), especialmente cuando se calibra con Datos de Trayectoria de Usuarios (GPS). El objetivo es sintetizar el estado del arte sobre cómo la inferencia estadística rigurosa, aplicada a datos de movilidad de alta resolución, mejora la precisión y el detalle del comportamiento de los agentes en los entornos urbanos.

2. Análisis Metodológico y Tecnológico

2.1. El Rol de la Máxima Verosimilitud (MLE) en la Calibración

La MLE es la técnica estadística dominante (presente en más del 60 % de los estudios) para la calibración de parámetros en modelos de elección. En el contexto de los modelos de movilidad, el agente se simula como un tomador de decisiones racional, y la MLE se utiliza para:

- **Cuantificar Preferencias (Modelos Logit/Probit):** Se utiliza MLE para estimar los coeficientes de las variables (ej., tiempo, coste) que maximizan la probabilidad de que la elección modelada coincida con la elección observada del agente (Art. 4, 7, 11, 13, 16-20, 22, 25).
- **Estimación de Demanda Dinámica (Modelos RDP/DRNN):** La MLE es fundamental para calibrar modelos que estiman la demanda no satisfecha de servicios de taxis, como en el estudio de Wang et al. (2023, Art. 5), que usa el Modelo de Probabilidad de Descomposición Recursiva (RDP), o en el trabajo de Lee y Lee (2020, Art. 14), que aplica MLE a una Red Neuronal Recurrente Profunda (DRNN) para la predicción espaciotemporal de la demanda de taxis.

2.2. Modelado de Agentes y la Calibración de la Heterogeneidad

Si bien pocos artículos usan el término explícito ABM, el enfoque de elección discreta es inherentemente basado en agentes:

- **Modelos de Elección Discreta:** Modelan el comportamiento de elección de modo de transporte de agentes individuales (viajeros, turistas, usuarios de MaaS) (Art. 4, 7, 13, 16).
- **Captura de Heterogeneidad:** Los modelos avanzados de elección discreta, como el Logit Ordenado Dinámico para la reubicación residencial (Art. 24) o el Modelo de Clase Latente (LCM) (Art. 15), utilizan MLE para identificar diferentes grupos de agentes (clases latentes) con patrones de comportamiento heterogéneos, permitiendo una calibración más matizada que los modelos Logit estándar.

2.3. Uso de Datos GPS y Trayectoria de Alta Resolución

La precisión de la calibración con MLE depende directamente de la calidad del dato de entrada. La tendencia es migrar de encuestas estáticas a datos dinámicos análogos a GPS:

Estudio	Año	Algoritmo Central	Tipo de Datos de Trayectoria / Uso en Calibración
Wang, J. et al.	2023	RDP (MLE)	Trayectoria GPS (Taxis) / Calibración de la demanda total (observada y no satisfecha).
Joo, H. et al.	2025	WMC con MLE	Simulación de Trayectoria VANET / Calibración de precisión de sincronización de tiempo.
Lee, H. et al.	2025	CollaGAN	Smart Card (Análogo a trayectoria de TP) / Fusión con HTS para generar horarios de actividad heterogéneos.
Yang, L. et al.	2022	IDMD Hawkes	IPDRs/Teléfonos Móviles (Análogo a trayectoria) / Calibración de interacciones espaciales dinámicas entre regiones.

El estudio de Wang et al. (2023, Art. 5) es el ejemplo más directo, utilizando datos de trayectoria GPS de taxis para calibrar los parámetros del modelo RDP mediante MLE, demostrando que esta metodología supera la simple observación de la demanda y permite estimar con precisión la demanda latente o no satisfecha.

3. Conclusión

La calibración de modelos de movilidad urbana basados en agentes mediante inferencias de Máxima Verosimilitud a partir de datos GPS de usuarios representa la frontera actual de la modelización urbana.

Conclusión Breve: La Máxima Verosimilitud sigue siendo el motor estadístico principal para calibrar los parámetros de utilidad en los modelos de comportamiento de agentes. La migración de datos de encuestas a datos de trayectoria GPS, tarjetas inteligentes y teléfonos móviles es fundamental, ya que permite la estimación robusta de la demanda no satisfecha y la captura de la heterogeneidad espaciotemporal de los agentes (Art. 5, 2), superando las limitaciones del modelado estático y mejorando la precisión predictiva para la planificación de infraestructura y servicios.

4. Referencias Clave

Esta revisión se basa en una síntesis de los siguientes 26 artículos (ordenados alfabéticamente por autor principal dentro de cada año relevante):

- 2025 (Calibración de punta):
 - Joo, H. et al. (2025). *Efficient One-Way Time Synchronization for VANET with MLE-Based Multi-Stage Update*.
 - Lee, H. et al. (2025). *Collaborative generative adversarial networks for fusing household travel survey and smart card data...*
- 2023 (Foco en GPS/Demanda Latente):
 - Gu, H. et al. (2023). *Understanding Intercity Mobility Patterns in Rapidly Urbanizing China... (PPML)*.
 - Wang, J. et al. (2023). *Recursive decomposition probability model for demand estimation of street-hailing taxis utilizing GPS trajectory data. (RDP/MLE)*.
- 2022 (Foco en Big Data de Agentes):
 - Yang, L. et al. (2022). *Individual Differentiated Multidimensional Hawkes Model... Using Mobile-Phone Data*.
- 2020 (Modelos Logit y DRNN):
 - Alvarez-Risco, A. et al. (2020). *Analysis of the use and preference for the electric car in the Peruvian population... (Logit)*.
 - Harbering, M.; Schlüter, J.C. (2020). *Determinants of transport mode choice in metropolitan areas... (Logit Multinomial)*.
 - Lee, M.H.; Lee, C.W. (2020). *A spatiotemporal prediction model for taxi demand using deep recurrent neural networks with maximum likelihood estimation. (DRNN-MLE)*.
 - Ying, T. et al. (2020). *Understanding the heterogeneity in residential location choice: A latent class model approach. (LCM/MLE)*.

■ 2015–2019 (Fundamentos Logit):

- Ahmadi, F. et al. (2018). *Assessment of the level of services in the use of public transport using the Logit model...*
- Li, Y. et al. (2016). *Analysis of travelers' choice of intercity public transport mode... (Logit Anidado)*.
- Mishra, D. et al. (2018). *Predicting the use of alternative fuels... using multinomial logit model.*
- Pani, A.K. et al. (2018). *Exploring the determinants of walking, cycling and public transit trips... (Logit Multinomial)*.
- Ramadurai, G.; Ranganathan, P. (2018). *A comprehensive modeling framework for intercity travelers' mode choice... (Logit Multinomial)*.
- Tizani, W.; AlQadhi, F. (2019). *Logit model analysis of factors affecting commuters' choice of public transport mode...*
- Wang, J. et al. (2017). *Analyzing factors affecting passenger satisfaction with urban rail transit using the Logit model.*